UNIVERSIDADE POLITÉCNICA DO CÁVADO E DO AVE

Trabalho Prático I

Plataforma de Gestão de Alojamento Local Reservas, Pagamentos e Extratos de Proprietários

Paulo Silva
N.º 31506

Docentes: Luís Ferreira e Óscar Ribeiro

Regime Diurno

Integração de Sistemas de Informação

Licenciatura em Engenharia de Sistemas Informáticos

Escola Superior de Tecnologia

Universidade Politécnica do Cávado e do Ave

Outubro de 2026

Índice

1. Enquadramento 3
1.1 Identificação do trabalho 3
1.2 O que é um processo ETL 3
1.3 A ferramenta: Pentaho Data Integration 3
2. Problema 5
2.1 Contexto 5
2.2 O que se pretende resolver 5
2.3 Dados de origem 5
2.4 Regras de negócio 7
3. Estratégia utilizada 8
3.1 Visão geral 8
3.2 Operadores utilizados 8
3.3 Expressões regulares 10
3.4 Decisões de projeto 10
4. Transformações 11
4.1 proprietarios.ktr 11
4.2 alojamentos.ktr 13
4.3 despesas.ktr 14
4.4 reservas_a.ktr e reservas_b.ktr 15
4.5 reservas.ktr 18
4.6 pagamentos.ktr 19
4.7 consolidacao.ktr 21
4.8 exportacao.ktr 22
4.9 extrato_html.ktr 23
5. Jobs 25
5.1 Job: etl_alojamento.kjb 25
6. Vídeo e repositório 26
7. Conclusão e trabalhos futuros 27
8. Referências bibliográficas 28

Índice de Figuras

Figura 1 - Visão geral do processo 8
Figura 2 - Transformação proprietarios.ktr no Spoon e respetivos resultados 12
Figura 3 - Transformação alojamentos.ktr no Spoon e respetivos resultados 14
Figura 4 - Transformação despesas.ktr no Spoon e respetivos resultados 15
Figura 5 - Transformação reservas_a.ktr no Spoon e respetivos resultados 17
Figura 6 - Transformação reservas_b.ktr no Spoon e respetivos resultados 17
Figura 7 - Transformação reservas.ktr no Spoon e respetivos resultados 19
Figura 8 - Transformação pagamentos.ktr no Spoon e respetivos resultados 20
Figura 9 - Transformação consolidacao.ktr no Spoon e respetivos resultados 22
Figura 10 - Transformação exportacao.ktr no Spoon e respetivos resultados 23
Figura 11 - Transformação extrato_html.ktr no Spoon e respetivos resultados 24
Figura 12 - Extrato final em HTML, gerado com XSL 24
Figura 13 - Job etl_alojamento.kjb no Spoon 25
Figura 14 - Email recebido com o ficheiro zip em anexo 26
Figura 15 - Código QR para o vídeo de demonstração 26

Índice de Tabelas

Tabela 1 - Diferenças entre transformação e job 4
Tabela 2 - Origens de dados do trabalho 6
Tabela 3 - Erros colocados propositadamente nos dados de origem 6
Tabela 4 - Operadores do Pentaho usados em cada fase 9
Tabela 5 - Expressões regulares usadas no trabalho 10
Tabela 6 - Resumo das transformações 11
Tabela 7 - Passos da transformação proprietarios 12
Tabela 8 - Passos da transformação alojamentos 13
Tabela 9 - Passos da transformação despesas 14
Tabela 10 - Passos das transformações reservas_a e reservas_b 16
Tabela 11 - Passos da transformação reservas 18
Tabela 12 - Passos da transformação pagamentos 19
Tabela 13 - Passos da transformação consolidação 21
Tabela 14 - Passos da transformação exportacao 22
Tabela 15 - Passos da transformação extrato_html 24

1. Enquadramento

O presente capítulo enquadra o trabalho desenvolvido no âmbito da unidade curricular de Integração de Sistemas de Informação, define o conceito de processo ETL e apresenta a ferramenta utilizada, o Pentaho Data Integration.

1.1 Identificação do trabalho

Este relatório descreve o Trabalho Prático I da unidade curricular de Integração de Sistemas de Informação (ISI), da Licenciatura em Engenharia de Sistemas Informáticos, no ano letivo 2026/27. O trabalho foi realizado individualmente pelo aluno n.º 31506.

O enunciado pede o desenvolvimento de um processo ETL em que o aluno define o tema, com dados reais ou inventados, e o implementa numa ferramenta à escolha. O processo tem de passar por três fases: recolha de dados em formatos e origens diferentes, transformação com a lógica de negócio e, no fim, persistência e exportação dos resultados.

A escolha foi o Pentaho Data Integration (Spoon, versão 10.2) e o tema gestão de alojamentos locais, que é descrito no capítulo 2.

1.2 O que é um processo ETL

ETL é a sigla de Extract, Transform and Load, ou seja, extrair, transformar e carregar. É o nome que se dá ao conjunto de passos que vai buscar dados a uma ou mais origens, os trata e os grava num destino onde possam ser consultados e usados.

Na prática, serve para juntar dados que estão em sítios diferentes, com formatos e qualidade diferentes, num resultado único e coerente. Cada letra corresponde a uma fase com um papel próprio. Na extração, os dados são lidos das origens, que podem ser ficheiros (CSV, XML, JSON), bases de dados ou serviços web. Na transformação, os dados são limpos e adaptados às regras do negócio: validam-se campos, removem-se duplicados, convertem-se tipos e formatos, cruzam-se tabelas e fazem-se cálculos e agregações.

Na carga, o resultado é gravado no destino, que normalmente é uma base de dados, mas também pode ser um ficheiro de exportação ou uma mensagem enviada a outro sistema. Fonte: (Amazon Web Services)

1.3 A ferramenta: Pentaho Data Integration

O Pentaho Data Integration (PDI), também conhecido por Kettle, é uma ferramenta de ETL onde os processos se constroem de forma gráfica, ligando blocos num ecrã, sem ser necessário escrever código para o essencial. A interface de desenho chama-se Spoon.

Os processos guardam-se em dois tipos de ficheiro:

• Transformações (.ktr): tratam dados. São feitas de passos (steps) ligados por setas (hops), e as linhas de dados vão passando de passo em passo.

• Jobs (.kjb): orquestram o trabalho. São feitos de entradas (entries) que executam uma a seguir à outra, por exemplo correr uma transformação, comprimir ficheiros ou enviar um email.

A Tabela 1 resume as diferenças entre os dois tipos de ficheiro.

Tabela 1 - Diferenças entre transformação e job

	Transformação (.ktr)	**Job (.kjb)**
Função	Tratar dados: ler, validar, converter, cruzar, escrever	Controlar o fluxo: ordem de execução, ficheiros, email, zip
Elementos	Passos (steps) e ligações (hops)	Entradas (entries) e ligações (hops)
Execução	Passos a correr em paralelo, com linhas de dados a circular	Entradas em sequência, uma de cada vez
Neste trabalho	10 transformações	1 job principal

Fonte: (Pentaho)

2. Problema

Este capítulo descreve o problema que o trabalho pretende resolver, o contexto em que surge, os dados de origem disponíveis e as regras de negócio que o resultado tem de cumprir.

2.1 Contexto

Imagina-se uma empresa de gestão de alojamento local, que trata dos alojamentos de vários proprietários. Os proprietários não gerem nada: o alojamento é publicado em duas plataformas de reservas, os hóspedes pagam e a empresa fica com uma comissão e paga as despesas de manutenção e limpeza. No fim de cada mês, cada proprietário quer saber quanto lhe cabe.

O problema é que a informação necessária está espalhada por origens diferentes, cada uma com o seu formato e as suas falhas. Os dados dos proprietários e dos alojamentos vêm de um ficheiro XML do sistema de gestão. As reservas chegam em dois CSV, um por plataforma, e os dois formatos não coincidem (separadores, datas e nomes de colunas diferentes). As despesas estão num terceiro CSV e os pagamentos num JSON. Alguns pagamentos são em dólares, o que obriga a consultar uma taxa de câmbio.

2.2 O que se pretende resolver

O objetivo é produzir, para cada proprietário e para cada mês, um extrato com a seguinte conta:

valor líquido = receita dos pagamentos confirmados − comissão da empresa − despesas de gestão

Para isto ser fiável, o processo tem de garantir que só entram dados válidos. Reservas com datas trocadas, pagamentos duplicados, proprietários com NIF ou email inválidos e despesas para alojamentos que não existem não podem contaminar o resultado. Em vez de simplesmente apagar esses registos, guardam-se em ficheiros de rejeitados, que servem de prova do que foi deixado de fora.

2.3 Dados de origem

Os dados são fictícios e foram criados para este trabalho, com erros colocados de propósito (valores em falta, duplicados, formatos de data diferentes, campos inválidos), de modo a justificar as fases de limpeza e validação.

A Tabela 2 resume as origens e a Tabela 3 os erros introduzidos.

Tabela 2 - Origens de dados do trabalho

Ficheiro / serviço	Formato	Conteúdo	Registos
gestao_proprietarios _alojamentos.xml	XML	Proprietários (nome, NIF, email, telefone, comissão) e alojamentos (localidade, quartos, preço por noite)	4 proprietários e 8 alojamentos
despesas.csv	CSV	Despesas de manutenção, reparação, limpeza por alojamento	43
reservas_plataforma_a.csv	CSV	Reservas do canal A. Separador ;, datas dd/mm/aaaa	34
reservas_plataforma_b.csv	CSV	Reservas do canal B. Separador ,, datas aaaa-mm-dd, só em euros	41
pagamentos.json	JSON	Pagamentos com estado (pago, pendente, falhado), moeda e data	67
API Frankfurter	REST / JSON	Taxa de câmbio EUR para USD e GBP numa data indicada	1 pedido por pagamento

Tabela 3 - Erros colocados propositadamente nos dados de origem

Origem	Problema	Como é tratado
XML	NIF com 8 dígitos (P03); email com @@ (P02); alojamento com 0 quartos (A04)	Regex Evaluation e Filter Rows
CSV canal A	Email sem @ ou vazio; nomes com espaços e maiúsculas; datas com - em vez de /; checkout antes do checkin; linhas duplicadas	Replace in string, String operations, Select values, Filter rows, Unique rows
CSV canal B	Nomes em minúsculas; linha duplicada; alojamento inexistente (A99)	String operations, Unique rows, Stream lookup
CSV despesas	Valor com vírgula decimal (207,00); valor igual a zero	Replace in string, Filter rows
JSON	pagamentos sem data (pendentes e falhados); pagamentos de reservas que não existem	Filter rows, Stream lookup

2.4 Regras de negócio

Antes de desenhar as transformações, fixei as regras que o extrato tem de respeitar:

- Só conta como receita um pagamento com estado pago, ligado a uma reserva válida e um alojamento válido.
- O mês do extrato é o mês da data do pagamento.
- Os pagamentos em dólares ou libras são convertidos para euros com a taxa de câmbio da data do pagamento.
- A comissão é a percentagem de cada proprietário.
- As despesas entram no mês da data da despesa.
- Um proprietário com NIF, email ou telefone inválido não tem extrato. Os valores que lhe pertenceriam ficam num ficheiro à parte.
- Os dados pessoais dos hóspedes (nome e email) são anonimizados antes de serem gravados.

3. Estratégia utilizada

Este capítulo apresenta a estratégia seguida no desenvolvimento do trabalho, nomeadamente a organização do processo em fases, os operadores, as expressões regulares utilizados e as principais decisões de projeto.

3.1 Visão geral

Organizei o trabalho nas três fases pedidas no enunciado. Na extração leio cinco ficheiros de três formatos (XML, CSV e JSON) e faço chamadas a uma API REST. Na transformação limpo e valido cada origem, junto-as com joins e lookups, calculo valores e agrego por proprietário e mês. Na carga exporto o extrato em quatro formatos, gravo-o numa base de dados SQL Server e envio um zip por email. A Figura 1 mostra o conjunto completo.

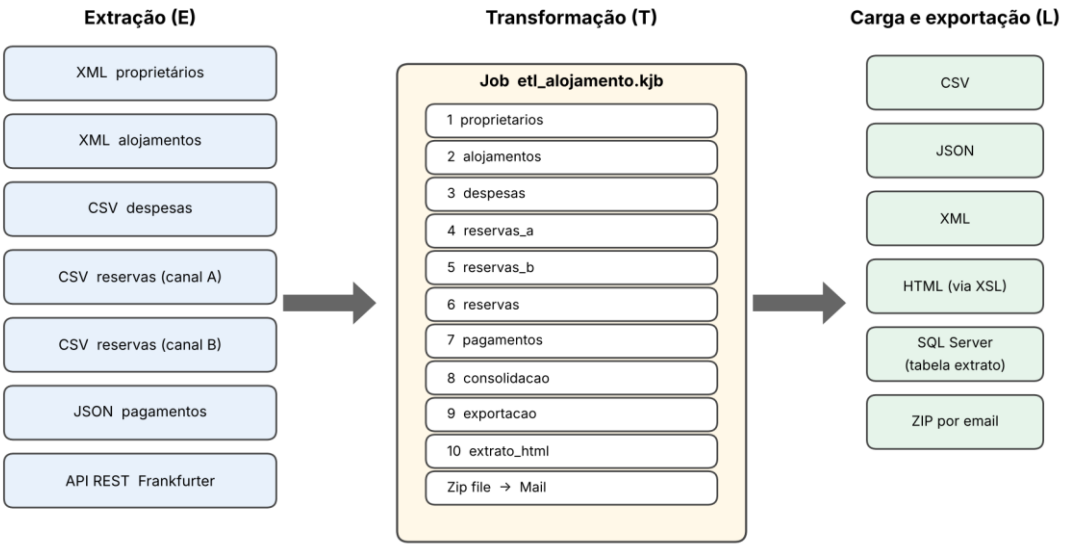


Figura 1 - Visão geral do processo

Em vez de construir uma única transformação, dividi o trabalho em transformações pequenas, uma por origem ou por assunto. Facilita a depuração, porque posso correr e testar cada uma isoladamente, e cada uma grava o seu resultado em CSV na pasta data/output. As transformações seguintes leem esses ficheiros. Ficou assim também mais fácil de mostrar o que cada passo produziu e de demonstrar o que foi rejeitado.

3.2 Operadores utilizados

A Tabela 4 resume os passos do Spoon que usei e para que servem no trabalho. No total foram utilizados mais de vinte tipos de passo, além das entradas do Job.

Tabela 4 - Operadores do Pentaho usados em cada fase

Fase	Operador	Onde e para quê
E	CSV file input	Ler despesas e reservas dos dois canais; ler os resultados intermédios nas transformações seguintes
E	Get data from XML	Ler proprietários e alojamentos do ficheiro de gestão
E	JSON input	Ler os pagamentos e interpretar a resposta da API de câmbios
E	REST client	Pedir à API Frankfurter a taxa de câmbio da data de cada pagamento
T	Replace in string	Normalizar telefones, trocar vírgula decimal por ponto, corrigir datas, anonimizar hóspedes
T	Regex Evaluation	Validar o formato do email, do NIF e do telefone
T	String operations	Remover espaços, pôr nomes com maiúscula inicial e emails em minúsculas
T	Select values	Mudar tipos de dados (texto para número ou data), renomear e reordenar colunas
T	Filter rows	Separar registos válidos de rejeitados em cada transformação
T	Sort rows / Unique rows	Ordenar e remover duplicados
T	Append streams	Juntar as reservas dos dois canais num único fluxo
T	Add constants	Acrescentar a moeda EUR ao canal B
T	Stream lookup	Cruzar reservas com alojamentos, pagamentos com reservas, despesas com alojamentos e receita com proprietários
T	Calculator	Calcular noites, valor da reserva, ano e mês
T	Formula	Montar o endereço da API, converter para euros, calcular comissão e líquido
T	Group by	Somar receita e despesas por proprietário, ano e mês
L	Text file output	Gravar os CSV de resultados e de rejeitados, e o HTML final
L	JSON output / XML output	Exportar o extrato em JSON e em XML
L	Table output	Carregar o extrato na tabela extrato do SQL Server
L	Load file content in memory / XSL transformation	Ler o XML do extrato e transformá-lo em HTML com uma folha XSL
Job	Transformation, Zip file, Delete filenames from result, Mail	Orquestrar as transformações, comprimir os ficheiros e enviar o email

3.3 Expressões regulares

As expressões regulares aparecem em duas situações: validar campos e transformar texto. A Tabela 5 lista as expressões utilizadas.

Tabela 5 - Expressões regulares usadas no trabalho

Utilização	Expressão	Efeito
Validar email	.+@.+\..+	Exige um @ e, depois dele, um ponto.
Validar NIF	[0-9]{9}	Exige exatamente 9 dígitos
Validar telefone	[0-9]{9}	Exige exatamente 9 dígitos
Normalizar telefone (1)	[^0-9]	Remove tudo o que não é dígito (espaços, +)
Normalizar telefone (2)	^351	Remove o indicativo de Portugal, ficando 912345678
Anonimizar nome	[^A-Z]	Substitui por * tudo o que não é letra maiúscula nem espaço
Anonimizar email	^[^@]+	Substitui a parte antes do @ por ***

Fonte: elaboração própria, com apoio de Claude (Anthropic, 2026)

3.4 Decisões de projeto

Ao longo do desenvolvimento tomei algumas decisões que convém registar, porque afetam os resultados:

- Rejeitados em ficheiro, nunca apagados - Cada transformação com validação grava um CSV de rejeitados.
- Câmbio pela data do pagamento - Numa primeira versão usei uma taxa única, a do dia em que o processo corre, mas isso dava um valor diferente consoante o dia da execução. Passei a pedir à API a taxa de cada data de pagamento, o que torna o resultado estável.
- Só há extrato nos meses com receita - Se um proprietário não teve nenhum pagamento confirmado num mês, esse mês não aparece.
- SQL Server como base de dados de destino - Optei pelo SQL Server por ser a base de dados com que estou mais familiarizado e que já tinha instalada, o que me permitiu concentrar o esforço nas transformações.

4. Transformações

O processo tem 10 transformações. Nesta secção descrevo cada uma, com a lista de passos e os resultados que obtive.

A Tabela 6 dá uma visão de conjunto.

Tabela 6 - Resumo das transformações

N.º	Transformação	Entrada	Saída (pasta data/output)
1	proprietarios.ktr	XML de gestão	proprietarios_validos.csv, proprietarios_rejeitados.csv
2	alojamentos.ktr	XML de gestão	alojamentos_validados.csv, alojamentos_rejeitados.csv
3	despesas.ktr	despesas.csv	despesas_validadas.csv, despesas_rejeitadas.csv
4	reservas_a.ktr	reservas_plataforma_a.csv	reservas_a.csv
5	reservas_b.ktr	reservas_plataforma_b.csv	reservas_b.csv
6	reservas.ktr	reservas_a.csv, reservas_b.csv, alojamentos_validados.csv	reservas_validas.csv, reservas_rejeitadas.csv, reservas_rejeitadas_alojamento.csv
7	pagamentos.ktr	pagamentos.json, API de câmbios	pagamentos_validados.csv, pagamentos_rejeitados.csv
8	consolidacao.ktr	Resultados das transformações 1, 2, 3, 6 e 7	extrato_proprietarios.csv e ficheiros de registos sem correspondência
9	exportacao.ktr	extrato_proprietarios.csv	JSON, XML e tabela extrato no SQL Server
10	extrato_html.ktr	extrato_proprietarios.xml, extrato.xsl	extrato_proprietarios.html

4.1 proprietarios.ktr

Objetivo**:** Ler os proprietários do XML, normalizar o telefone, validar os campos e separar os proprietários válidos dos rejeitados.

A Tabela 7 descreve cada passo da transformação e a Figura 2 mostra-a construída no Spoon, bem como os resultados obtidos. O fluxo segue da esquerda para a direita: lê-se o XML, normaliza-se o telefone, convertem-se os tipos e fazem-se as três validações (email, NIF e telefone), terminando num filtro que encaminha os registos válidos e rejeitados para ficheiros CSV separados.

Tabela 7 - Passos da transformação proprietarios

Passo	Tipo	O que faz
XML Proprietarios	Get data from XML	Lê cada elemento proprietario: id, nome, NIF, email, telefone e a percentagem de comissão
Normalizar Telefone	Replace in string	Com duas expressões regulares, tira os caracteres que não são dígitos e o indicativo 351
Converter	Select values	Passa a comissão a número e acerta os tipos dos restantes campos
Validar Email	Regex Evaluation	Cria o campo email_ok (Y/N) com a regex do email
Validar NIF	Regex Evaluation	Cria nif_formato_ok com a regex de 9 dígitos
Validar Telefone	Regex Evaluation	Cria telefone_ok com a regex de 9 dígitos
Dados Validos	Filter rows	Deixa passar quem tem as três validações a Y e comissão superior a zero
Validos CSV / Rejeitados CSV	Text file output	Gravam os dois resultados

Resultado. Dos 4 proprietários lidos, 2 são válidos (P01 e P04) e 2 foram rejeitados. O P02 foi rejeitado por ter o email joao.almeida@@email, com dois @, e o P03 por ter um NIF com 8 dígitos. Na Figura 2 podem ver-se a transformação e o conteúdo dos dois ficheiros de saída, proprietarios_validos.csv e proprietarios_rejeitados.csv, onde as colunas email_ok, nif_formato_ok e telefone_ok indicam qual a validação que falhou em cada registo.

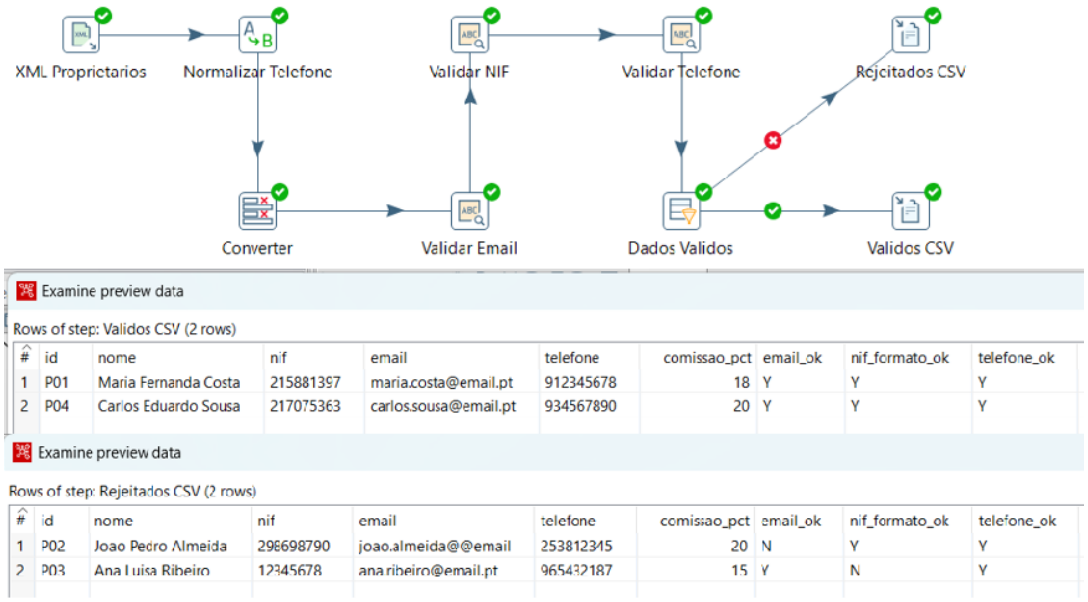


Figura 2 - Transformação proprietarios.ktr no Spoon e respetivos resultados

4.2 alojamentos.ktr

Objetivo**:** Ler os alojamentos do mesmo XML, converter os tipos de dados, remover duplicados e validar os campos, separando os alojamentos válidos dos rejeitados, para que só os completos sejam cruzados com as reservas e as despesas.

A Tabela 8 descreve cada passo da transformação e a Figura 3 mostra-a construída no Spoon, bem como os resultados obtidos. O fluxo segue da esquerda para a direita: lê-se o XML, convertem-se os tipos (quartos para inteiro e preço por noite para número), ordenam-se os registos por id e removem-se os duplicados, terminando num filtro que encaminha os alojamentos válidos e rejeitados para ficheiros CSV separados.

Tabela 8 - Passos da transformação alojamentos

Passo	Tipo	O que faz
XML Alojamentos	Get data from XML	Lê id, proprietário, nome, localidade, número de quartos e preço por noite
Converter	Select values	Converte quartos para inteiro e preço para número
Ordenar por id	Sort rows	Ordena para o passo seguinte poder detetar duplicados
Remover Duplicados	Unique rows	Mantém um registo por id
Alojamento Valido	Filter rows	Exige todos os campos preenchidos, quartos > 0 e preco_noite_eur > 0
Alojamentos CSV / Rejeitados CSV	Text file output	Gravam os válidos e os rejeitados

Resultado**.** Foram lidos 8 alojamentos, dos quais 7 são válidos e 1 foi rejeitado. O alojamento A04 (Studio Sao Victor, em Braga) foi rejeitado por ter 0 quartos, o que não cumpre a regra de ter pelo menos um quarto. Na Figura 3 podem ver-se a transformação e o conteúdo dos dois ficheiros de saída, alojamentos_validados.csv e alojamentos_rejeitados.csv.

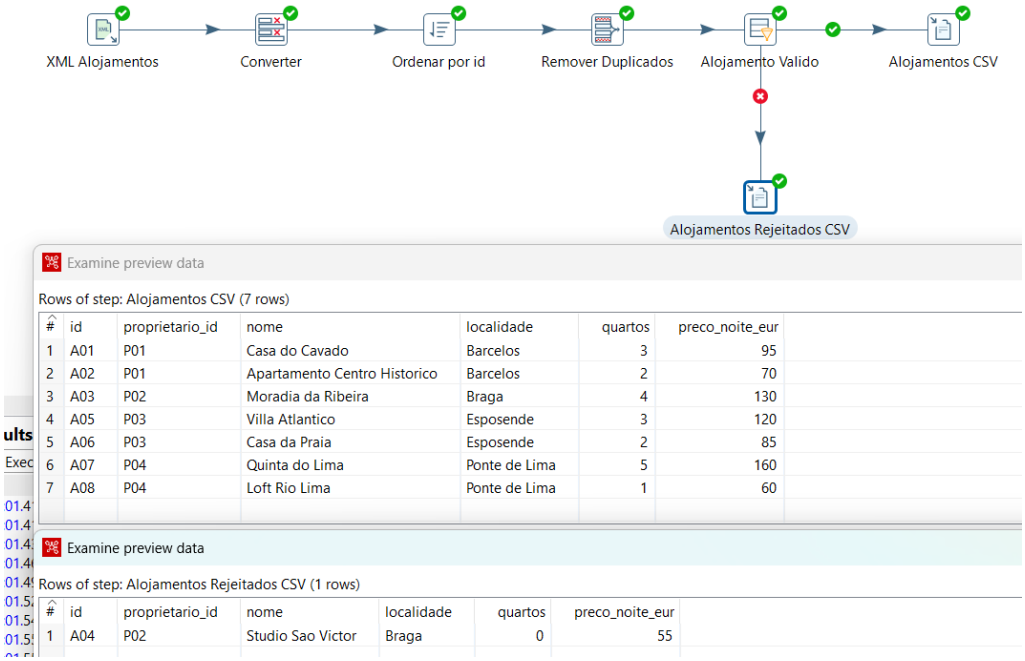


Figura 3 - Transformação alojamentos.ktr no Spoon e respetivos resultados

4.3 despesas.ktr

Objetivo: Limpar as despesas, corrigir os valores com vírgula decimal, validar os campos e acrescentar o ano e o mês de cada despesa, separando as despesas válidas das rejeitadas.

A Tabela 9 descreve cada passo da transformação e a Figura 4 mostra-a construída no Spoon, bem como os resultados obtidos. O fluxo segue da esquerda para a direita: lê-se o CSV, corrige-se a vírgula decimal, convertem-se os tipos e validam-se os campos obrigatórios e o valor. As despesas válidas recebem ainda o ano e o mês, necessários mais tarde para agrupar por mês, e os dois resultados são gravados em ficheiros CSV separados.

Tabela 9 - Passos da transformação despesas

Passo	Tipo	O que faz
CSV Despesas	CSV file input	Lê o ficheiro com separador ; e cabeçalho
Trocar Virgula	Replace in string	Troca a vírgula do campo valor por ponto, para 207,00 passar a 207.00
Converter Tipos	Select values	Valor para número e data da despesa para data
Validar Despesas	Filter rows	Exige valor > 0 e id, alojamento_id e data_despesa preenchidos
Calcular Mes	Calculator	Extrai ano e mes da data da despesa
Despesas CSV / Rejeitadas CSV	Text file output	Gravam os dois resultados

Resultado: O ficheiro tinha 43 despesas. Uma foi rejeitada por ter valor 0 e ficaram 42 despesas válidas, já com as colunas ano e mês. Na Figura 4 podem ver-se a transformação e o conteúdo dos dois ficheiros de saída, despesas_validadas.csv e despesas_rejeitadas.csv.

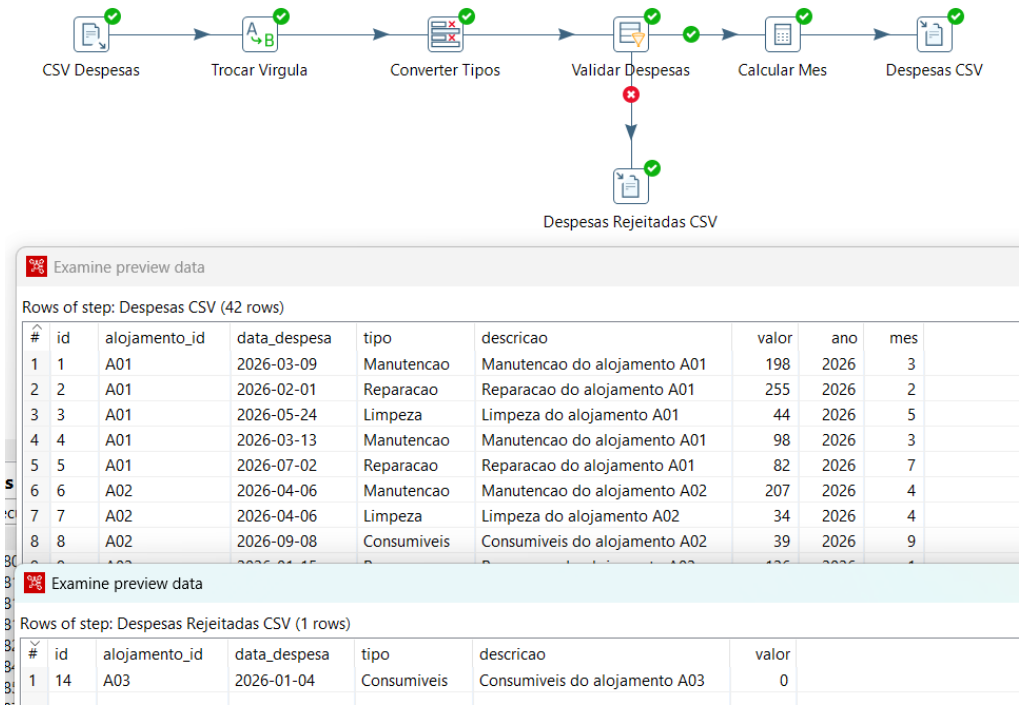


Figura 4 - Transformação despesas.ktr no Spoon e respetivos resultados

4.4 reservas_a.ktr e reservas_b.ktr

Objetivo: As duas plataformas enviam as reservas em formatos diferentes. Estas duas transformações lêem e limpam cada canal, verificam se os campos obrigatórios estão preenchidos e deixam os dois canais com as mesmas colunas e os mesmos tipos de dados, para poderem ser juntos na transformação seguinte.

A Tabela 10 descreve os passos das duas transformações e as Figuras 5 e 6 mostram-nas construídas no Spoon, bem como os resultados obtidos. O canal A usa ; como separador e datas dd/mm/aaaa; o canal B usa ,, datas aaaa-mm-dd, nomes de colunas diferentes (codigo, listing, guest, data_entrada) e não tem a coluna da moeda.

Por isso cada canal tem a sua transformação, e ambas gravam um CSV com as mesmas colunas: reserva_id, alojamento_id, hospede_nome, hospede_email, checkin, checkout e moeda. Em ambas, um filtro encaminha as reservas completas para o ficheiro de válidas e as que têm campos em falta para um ficheiro de rejeitadas.

Tabela 10 - Passos das transformações reservas_a e reservas_b

Passo	Tipo	O que faz
Canal A CSV Reservas A	CSV file input	Lê o ficheiro com separador ;
Datas A com barra	Replace in string	Troca - por / nas datas de check-in e check-out que vêm com o formato errado
Converter Datas A	Select values	Converte o texto dd/MM/yyyy para data
Limpar Texto	String operations	Retira espaços, põe maiúscula inicial no nome e minúsculas no email
Gravar A	Text file output	Grava reservas_a.csv
Verificação	Filter rows	Exige todos os campos preenchidos
Text file output	Text file output	Gravam as reservas válidas e as rejeitadas
Canal B CSV Reservas B	CSV file input	Lê o ficheiro com separador ,
Renomear B	Select values	Muda os nomes das colunas para o esquema do canal A
Moeda EUR	Add constants	Acrescenta a coluna moeda com o valor EUR, porque este canal só tem euros
Limpar Texto	String operations	Mesmo tratamento de texto que no canal A
Verificação	Filter rows	Exige todos os campos preenchidos
Gravar B / Rejeitadas B CSV	Text file output	Gravam as reservas válidas e as rejeitadas

Resultado: O canal A tem 34 reservas e o canal B 41. Em cada canal foram rejeitadas as reservas com campos em falta: 1 no canal A (BK-0006) e 2 no canal B (AB-0008 e AB-0017), ficando 33 e 39 válidas. As Figuras 5 e 6 mostram as duas transformações e os respetivos resultados.

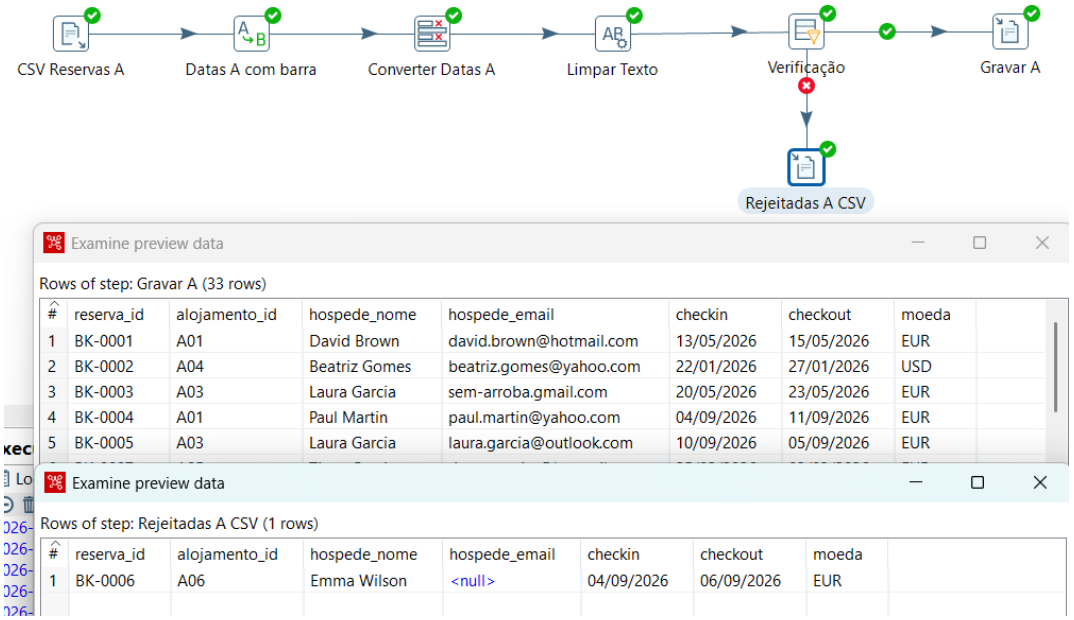


Figura 5 - Transformação reservas_a.ktr no Spoon e respetivos resultados

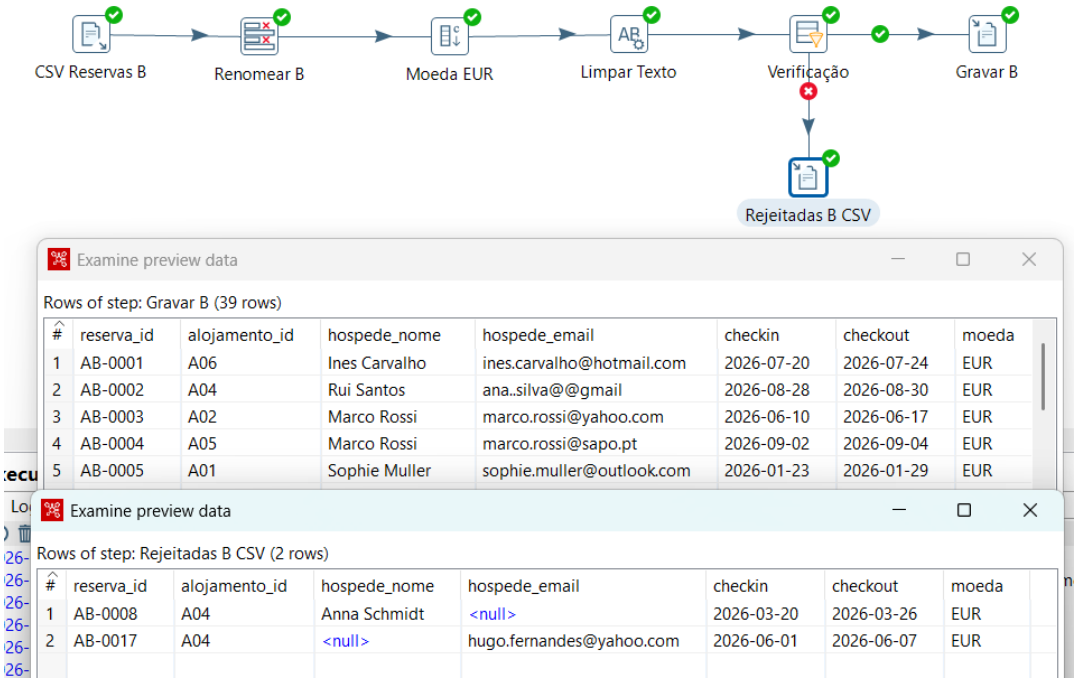


Figura 6 - Transformação reservas_b.ktr no Spoon e respetivos resultados

4.5 reservas.ktr

Objetivo: Juntar as reservas dos dois canais, remover duplicados, validar as datas e associar cada reserva ao respetivo alojamento e proprietário, calcular o número de noites e o valor e anonimizar os dados pessoais dos hóspedes.

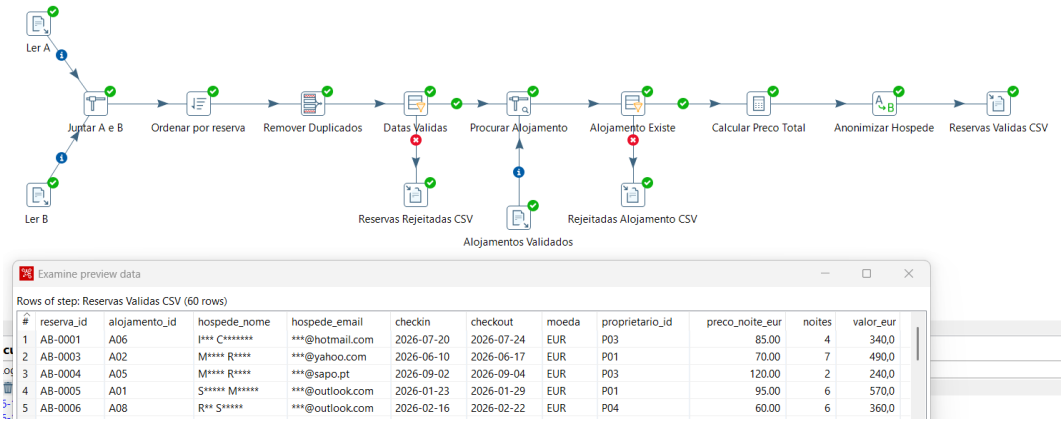
A Tabela 11 descreve os passos da transformação e a Figura 7 mostra-a construída no Spoon, bem como o resultado obtido. As reservas dos dois canais são lidas e juntas num único fluxo, ordenadas por reserva_id e sem duplicados. Depois passam por uma validação das datas e por um lookup aos alojamentos validados, que lhes associa o proprietário e o preço por noite.

Em seguida calcula-se o número de noites e o valor de cada reserva, e anonimizam-se o nome e o email dos hóspedes antes de gravar o resultado. As reservas rejeitadas em cada validação são gravadas em ficheiros próprios.

Tabela 11 - Passos da transformação reservas

Passo	Tipo	O que faz
Ler A / Ler B	CSV file input	Leem os dois ficheiros gravados nas transformações anteriores
Juntar A e B	Append streams	Põe as reservas dos dois canais no mesmo fluxo
Ordenar por reserva / Remover Duplicados	Sort rows / Unique rows	Mantém uma linha por reserva_id
Datas Validas	Filter rows	Deixa passar as reservas com check-in menor ou igual ao check-out. As outras vão para reservas_rejeitadas.csv
Procurar Alojamento	Stream lookup	Vai buscar a alojamentos_validados.csv o proprietário e o preço por noite. Se o alojamento não existir, o proprietário fica SEM
Alojamento Existe	Filter rows	Separa as reservas sem alojamento válido para reservas_rejeitadas_alojamento.csv
Calcular Preco Total	Calculator	Calcula noites (diferença entre datas) e valor_eur (noites vezes preço por noite)
Anonimizar Hospede	Replace in string	Aplica as regex de anonimização ao nome e ao email
Reservas Validas CSV	Text file output	Grava reservas_validas.csv

Resultado: Entraram 72 reservas (33 do canal A e 39 do canal B). Foram removidas 3 duplicadas, 1 foi rejeitada por ter o check-out antes do check-in (BK-0005) e 8 foram rejeitadas por pertencerem a alojamentos que não existem ou que foram rejeitados, como o A99 e o A04. Ficaram 60 reservas válidas, já com os hóspedes anonimizados, por exemplo I*** C******* e ***@hotmail.com, como se vê na Figura 7.



#	reserva_id	alojamento_id	hospede_nome	hospede_email	checkin	checkout	moeda	proprietario_id	preco_noite_eur	noites	valor_eur
1	AB-0001	A06	I*** C*******	***@hotmail.com	2026-07-20	2026-07-24	EUR	P03	85.00	4	340,0
2	AB-0003	A02	M**** R****	***@yahoo.com	2026-06-10	2026-06-17	EUR	P01	70.00	7	490,0
3	AB-0004	A05	M**** R****	***@sapo.pt	2026-09-02	2026-09-04	EUR	P03	120.00	2	240,0
4	AB-0005	A01	S***** M*****	***@outlook.com	2026-01-23	2026-01-29	EUR	P01	95.00	6	570,0
5	AB-0006	A08	R** S*****	***@outlook.com	2026-02-16	2026-02-22	EUR	P04	60.00	6	360,0

Figura 7 - Transformação reservas.ktr no Spoon e respetivos resultados

4.6 pagamentos.ktr

Objetivo: Ler os pagamentos do JSON, ficar só com os pagos, acrescentar o ano e o mês e converter para euros os que estão noutra moeda, usando a taxa de câmbio da data de cada pagamento.

A Tabela 12 descreve os passos da transformação e a Figura 8 mostra-a construída no Spoon, bem como o resultado obtido. Os pagamentos são lidos do JSON e filtram-se os que estão pagos. Para cada um, pede-se à API a taxa de câmbio da respetiva data, que é usada para converter o valor para euros.

Tabela 12 - Passos da transformação pagamentos

Passo	Tipo	O que faz
JSON Pagamentos	JSON input	Lê o array pagamentos do ficheiro, com um caminho JSONPath por campo
Converter	Select values	Valor para número e data de pagamento para data
Pagamento Valido	Filter rows	Exige estado = pago, data preenchida e valor > 0. O resto vai para pagamentos_rejeitados.csv
Calcular Mes	Calculator	Extrai ano e mes da data do pagamento
Montar URL	Formula	Constrói o endereço https://api.frankfurter.dev/v1/<data>?base=EUR&symbols=USD,GBP

Passo	Tipo	O que faz
Taxa da Data	REST client	Faz o pedido GET a esse endereço, uma vez por pagamento
Ler Taxa	JSON input	Lê da resposta as taxas $.rates.USD e $.rates.GBP
Converter para EUR	Formula	Se a moeda é EUR mantém o valor, senão divide pela taxa, e arredonda a 2 casas decimais
Pagamentos CSV	Text file output	Grava pagamentos_validados.csv com a coluna valor_eur
Pagamentos Rejeitados CSV	Text file output	Grava os pagamentos que não passaram a validação

Resultado: Foram lidos 67 pagamentos. Destes, 15 foram rejeitados (8 pendentes e 7 falhados), ficando 52 pagamentos válidos, dos quais 48 em euros e 4 em dólares.

A conversão usa a taxa do dia em que cada pagamento foi feito. Por exemplo, o pagamento PG-0008, de 691,20 USD feito a 20 de março, foi convertido à taxa de 1,1555 e dá 598,18 EUR. O arredondamento é feito com INT(valor × 100 + 0,5) / 100.

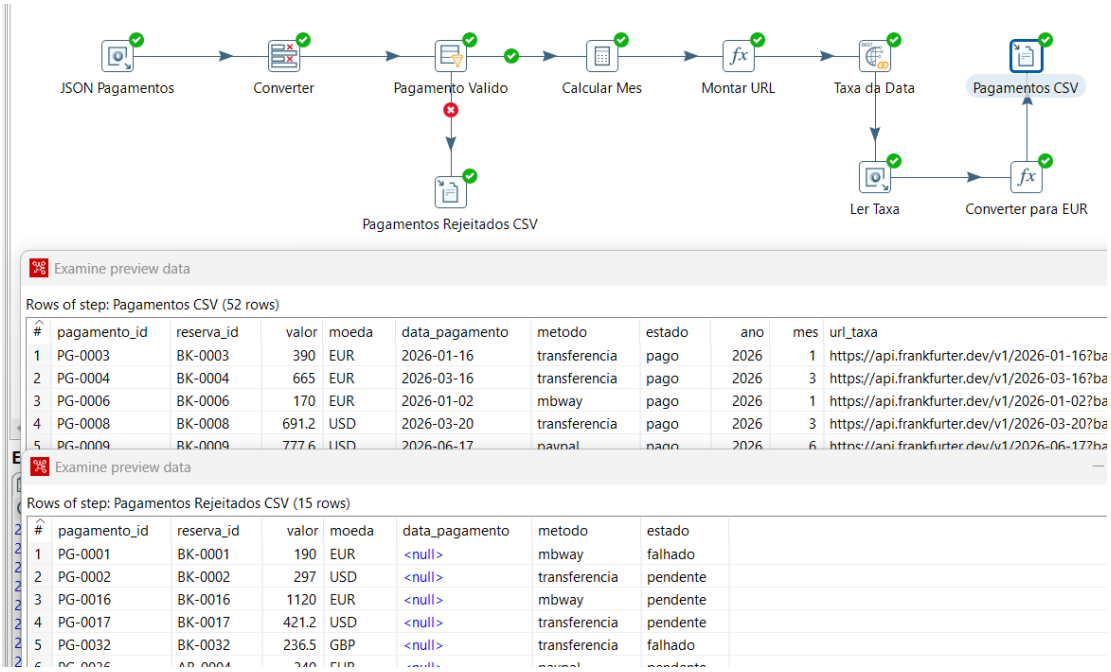


Figura 8 - Transformação pagamentos.ktr no Spoon e respetivos resultados

4.7 consolidacao.ktr

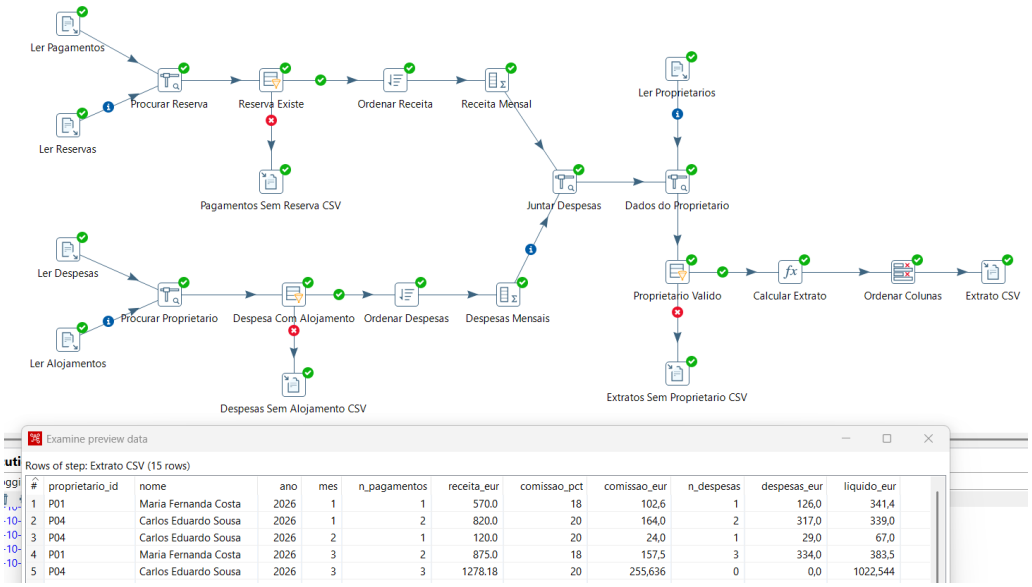
Objetivo: É a transformação central do trabalho. Junta pagamentos, reservas, despesas, alojamentos e proprietários e calcula o extrato mensal de cada proprietário.

A Tabela 13 descreve os passos da transformação e a Figura 9 mostra-a construída no Spoon, bem como o resultado obtido. É onde se cruzam todos os dados tratados anteriormente: agrupa-se a receita por proprietário e mês, agrupam-se as despesas, e juntam-se os dois resultados com os dados do proprietário para calcular a comissão e o valor líquido.

Tabela 13 - Passos da transformação consolidação

Passo	Tipo	O que faz
Ler Pagamentos / Ler Reservas	CSV file input	Leem pagamentos_validados.csv e reservas_validas.csv
Procurar Reserva	Stream lookup	Para cada pagamento, procura a reserva e traz o proprietário. Sem reserva válida, fica SEM
Reserva Existe	Filter rows	Os pagamentos sem reserva vão para pagamentos_sem_reserva.csv
Ordenar Receita / Receita Mensal	Sort rows / Group by	Agrupa por proprietário, ano e mês: soma de valor_eur (receita) e contagem de pagamentos
Ler Despesas / Ler Alojamentos	CSV file input	Leem as despesas e os alojamentos validados
Procurar Proprietario	Stream lookup	Liga cada despesa ao proprietário através do alojamento
Despesa Com Alojamento	Filter rows	As despesas sem alojamento válido vão para despesas_sem_alojamento.csv
Ordenar Despesas / Despesas Mensais	Sort rows / Group by	Agrupa por proprietário, ano e mês: soma das despesas e contagem
Juntar Despesas	Stream lookup	Acrescenta à receita mensal as despesas do mesmo proprietário, ano e mês (0 se não houver)
Ler Proprietarios / Dados do Proprietario	CSV file input / Stream lookup	Acrescentam o nome e a percentagem de comissão
Proprietario Valido	Filter rows	Os valores de proprietários que não são válidos vão para extratos_sem_proprietario.csv
Calcular Extrato	Formula	Comissão_eur = receita × comissão / 100; liquido_eur = receita – comissão – despesas
Ordenar Colunas / Extrato CSV	Select values / Text file output	Põem as colunas por ordem e gravam extrato_proprietarios.csv

Resultado: Dos 52 pagamentos válidos, 10 não têm reserva válida e ficaram de fora. Das 42 despesas válidas, 5 pertencem ao alojamento A04, que foi rejeitado, e também ficaram de fora. O extrato final tem 15 linhas, 7 de P01 e 8 de P04. As linhas dos proprietários P02 e P03 (11 no total) foram para extratos_sem_proprietario.csv.



#	proprietario_id	nome	ano	mes	n_pagamentos	receita_eur	comissao_pct	comissao_eur	n_despesas	despesas_eur	liquido_eur
1	P01	Maria Fernanda Costa	2026	1	1	570.0	18	102,6	1	126,0	341,4
2	P04	Carlos Eduardo Sousa	2026	1	2	820.0	20	164,0	2	317,0	339,0
3	P04	Carlos Eduardo Sousa	2026	2	1	120.0	20	24,0	1	29,0	67,0
4	P01	Maria Fernanda Costa	2026	3	2	875.0	18	157,5	3	334,0	383,5
5	P04	Carlos Eduardo Sousa	2026	3	3	1278.18	20	255,636	0	0,0	1022,544

Figura 9 - Transformação consolidacao.ktr no Spoon e respetivos resultados

4.8 exportacao.ktr

Objetivo: Exportar o extrato final em JSON e XML e carregá-lo na base de dados SQL Server, que é a fase de carga do processo.

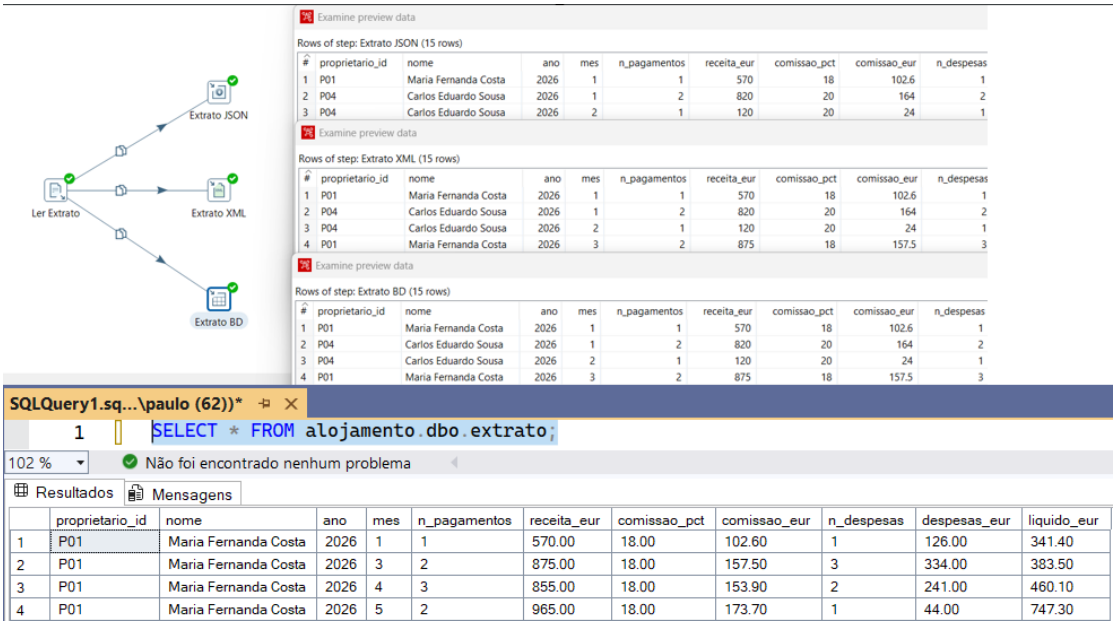
A Tabela 14 detalha os passos da transformação e a Figura 10 apresenta-a construída no Spoon, bem como os resultados obtidos. O extrato final é lido uma só vez e enviado em paralelo para três destinos: um ficheiro JSON, um ficheiro XML e a tabela extrato da base de dados SQL Server.

Tabela 14 - Passos da transformação exportacao

Passo	Tipo	O que faz
Ler Extrato	CSV file input	Lê extrato_proprietarios.csv. Está ligado aos três passos seguintes com a opção “Copy data to next steps”
Extrato JSON	JSON output	Grava extrato_proprietarios.json
Extrato XML	XML output	Grava extrato_proprietarios.xml, com extratos como elemento principal e extrato em cada linha. Os inteiros usam o formato 0 e os valores em euros o formato 0.00

Passo	Tipo	O que faz
Extrato BD	Table output	Insere as linhas na tabela dbo.extrato da base de dados alojamento, esvaziando a tabela antes de cada carga

Resultado: O extrato final foi exportado para os três destinos com as mesmas 15 linhas. A Figura 10 mostra a transformação, a pré-visualização de cada destino e, por baixo, o conteúdo da tabela extrato na base de dados alojamento, consultada no SQL Server Management Studio. A tabela tem como chave primária o conjunto proprietário, ano e mês, o que impede duas linhas para o mesmo mês do mesmo proprietário, e é esvaziada antes de cada carga, por isso executar o Job várias vezes não duplica registos.



	proprietario_id	nome	ano	mes	n_pagamentos	receita_eur	comissao_pct	comissao_eur	n_despesas	despesas_eur	liquido_eur
1	P01	Maria Fernanda Costa	2026	1	1	570.00	18.00	102.60	1	126.00	341.40
2	P01	Maria Fernanda Costa	2026	3	2	875.00	18.00	157.50	3	334.00	383.50
3	P01	Maria Fernanda Costa	2026	4	3	855.00	18.00	153.90	2	241.00	460.10
4	P01	Maria Fernanda Costa	2026	5	2	965.00	18.00	173.70	1	44.00	747.30

Figura 10 - Transformação exportacao.ktr no Spoon e respetivos resultados

4.9 extrato_html.ktr

Objetivo: Transformar o extrato em XML numa página HTML, usando uma folha de estilo XSL. Esta transformação mostra a conversão entre formatos de estrutura de dados (XML para HTML).

A Tabela 15 descreve os passos da transformação e a Figura 11 mostra-a construída no Spoon, bem como o resultado obtido. O XML do extrato é lido para um campo de texto, transformado em HTML através de uma folha XSL e gravado num ficheiro. A Figura 12 mostra a página obtida, aberta no browser.

Tabela 15 - Passos da transformação extrato_html

Passo	Tipo	O que faz
Load file content	Load file content in memory	Lê o ficheiro extrato_proprietarios.xml para um campo de texto
XSL transformation	XSL transformation	Aplica extrato.xsl ao campo com o XML e guarda o HTML gerado no campo result
Extrato HTML	Text file output	Grava extrato_proprietarios.html, sem aspas nem cabeçalho

Resultado: A folha extrato.xsl percorre os elementos extrato e cria uma tabela HTML com uma linha por proprietário e mês. Como se vê na Figura 11, a transformação trata o ficheiro como uma única linha, com o XML no campo File content e o HTML gerado no campo result, que é depois gravado em extrato_proprietarios.html. O resultado é a página da Figura 12, com os 15 meses do extrato.

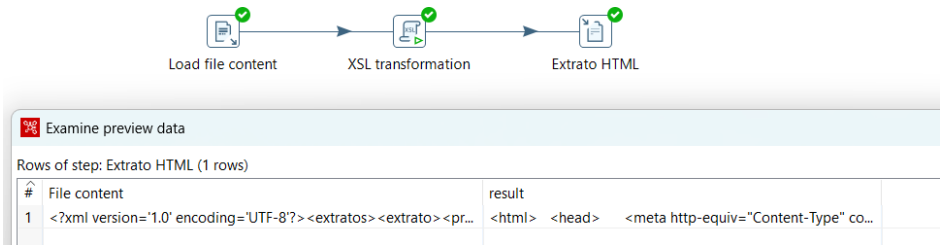


Figura 11 - Transformação extrato_html.ktr no Spoon e respetivos resultados

Extratos Mensais de Proprietários

Proprietário	Ano	Mês	Pagamentos	Receita (€)	Comissão %	Comissão (€)	Despesas (€)	Líquido (€)
Maria Fernanda Costa	2026	1	1	570.00	18	102.60	126.00	341.40
Carlos Eduardo Sousa	2026	1	2	820.00	20	164.00	317.00	339.00
Carlos Eduardo Sousa	2026	2	1	120.00	20	24.00	29.00	67.00
Maria Fernanda Costa	2026	3	2	875.00	18	157.50	334.00	383.50
Carlos Eduardo Sousa	2026	3	3	1278.18	20	255.64	0.00	1022.54
Maria Fernanda Costa	2026	4	3	855.00	18	153.90	241.00	460.10
Carlos Eduardo Sousa	2026	4	2	1060.00	20	212.00	0.00	848.00
Maria Fernanda Costa	2026	5	2	965.00	18	173.70	44.00	747.30
Carlos Eduardo Sousa	2026	5	2	1480.00	20	296.00	0.00	1184.00
Maria Fernanda Costa	2026	6	2	840.00	18	151.20	0.00	688.80
Carlos Eduardo Sousa	2026	6	2	1300.00	20	260.00	286.00	754.00
Maria Fernanda Costa	2026	8	3	1270.00	18	228.60	0.00	1041.40
Carlos Eduardo Sousa	2026	8	2	292.04	20	58.41	221.00	12.63
Maria Fernanda Costa	2026	9	2	770.00	18	138.60	162.00	469.40
Carlos Eduardo Sousa	2026	9	1	320.00	20	64.00	0.00	256.00

Figura 12 - Extrato final em HTML, gerado com XSL

5. Jobs

Este capítulo descreve o Job que orquestra as transformações e fecha o processo, os seus parâmetros e a forma como é executado.

5.1 Job: etl_alojamento.kjb

O Job etl_alojamento.kjb junta tudo e executa o processo completo com um só clique. A Figura 13 mostra-o construído no Spoon. Começa na entrada Start e depois corre as dez transformações pela ordem em que os dados dependem uns dos outros: proprietários, alojamentos, despesas, reservas do canal A, reservas do canal B, reservas, pagamentos, consolidação, exportação e extrato HTML.

A ordem importa, porque cada transformação lê ficheiros que as anteriores acabaram de gravar. Por exemplo, as reservas precisam dos alojamentos validados, e a consolidação precisa de tudo o que vem antes. Depois das transformações, o Job faz três coisas para fechar o processo:

1. Delete filenames from result - O Pentaho regista na lista de resultados do Job todos os ficheiros gravados pelos passos de escrita. Se o email fosse enviado nessa altura, levava muitos anexos em vez de apenas o zip. Limpo essa lista antes do zip, para ficar só o que interessa.
2. Zip file - Comprime os ficheiros extrato_proprietarios.* (CSV, JSON, XML e HTML) num zip. A origem é a pasta data/output e o filtro é a expressão regular .*extrato_proprietarios\..*. Como a opção é “Create new with unique name”, cada execução gera um zip novo, com a data e a hora no nome.
3. Mail - Envia o zip por email através do servidor SMTP do Gmail (porta 587, com TLS). O destinatário e a palavra-passe vêm de parâmetros do Job.

O final do Job é um email com o zip dos extratos em anexo, que se pode ver na Figura 14. O zip contém os quatro formatos do extrato (CSV, JSON, XML e HTML).

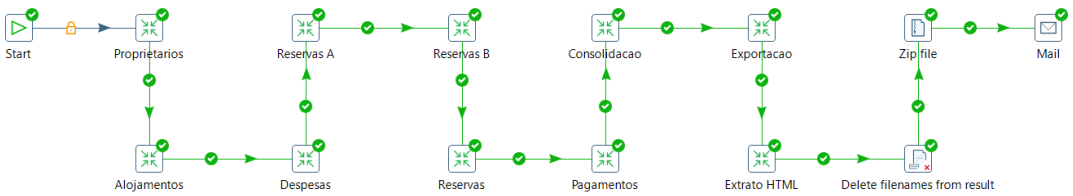


Figura 13 - Job etl_alojamento.kjb no Spoon



Figura 14 - Email recebido com o ficheiro zip em anexo

6. Vídeo e repositório

O vídeo mostra o processo a funcionar do princípio ao fim. Nele apresento as pastas do projeto, abro o Job no Spoon e executo-o, mostro os ficheiros que foram gerados (CSV, JSON, XML, HTML e o zip), a tabela no SQL Server e o email recebido com o anexo. O vídeo está disponível em https://youtu.be/9gY5OEQGIRM e também através do código QR da Figura 15.

O projeto completo, com os jobs, as transformações, os ficheiros de entrada e de saída de exemplo e o ficheiro XSL, está também disponível num repositório Git em https://github.com/wpaulosilva/tp01-31506.

Figura 15 - Código QR para o vídeo de demonstração

7. Conclusão e trabalhos futuros

O trabalho cumpre o objetivo definido: a partir de cinco origens em três formatos e de uma API, o processo produz um extrato mensal por proprietário, com a receita, a comissão, as despesas e o valor líquido, e entrega-o em CSV, JSON, XML, HTML, numa base de dados SQL Server e num email. O Job corre o processo todo de forma automática, e cada passo com validação deixa os seus registos rejeitados em ficheiro.

Em termos do enunciado, o processo cobre as três fases e vários dos critérios de mais-valia: expressões regulares na validação e na anonimização, importação e exportação em XML e JSON, conversão de XML para HTML com XSL, joins e lookups, agrupamentos, acesso a uma API REST, operações sobre uma base de dados e um Job com acesso a um serviço remoto de email.

Há ainda várias melhorias que ficaram de fora para não alargar demasiado o âmbito. A mais visível seria um dashboard, ligado à tabela extrato, em ferramentas como o Node-RED Dashboard, para cada proprietário acompanhar a evolução mensal da sua receita, comissão e despesas.

O extrato também poderia ser entregue em PDF: em vez de um zip único, o processo geraria um PDF por proprietário e enviá-lo-ia diretamente para o respetivo destinatário. Outra melhoria seria automatizar a execução, correndo o Job todos os meses e agendando-o no sistema, com um email de alerta se alguma entrada falhasse, e acrescentar um parâmetro de mês, que permitisse escolher o mês a processar e fazer cargas incrementais na base de dados, em vez de esvaziar a tabela de cada vez.

8. Referências bibliográficas

Amazon Web Services. (s.d.). What is ETL? Obtido de Amazon Web Services: https://aws.amazon.com/what-is/etl/

Anthropic. (2026). Obtido de Claude (Claude Sonnet 5.5): https://claude.ai

Pentaho. (s.d.). Basic concepts of PDI. Obtido de Pentaho Documentation (versão 10.2): https://docs.pentaho.com/pdia-data-integration/10.2-data-integration/data-integration-perspective-in-the-pdi-client/basic-concepts-of-pdi